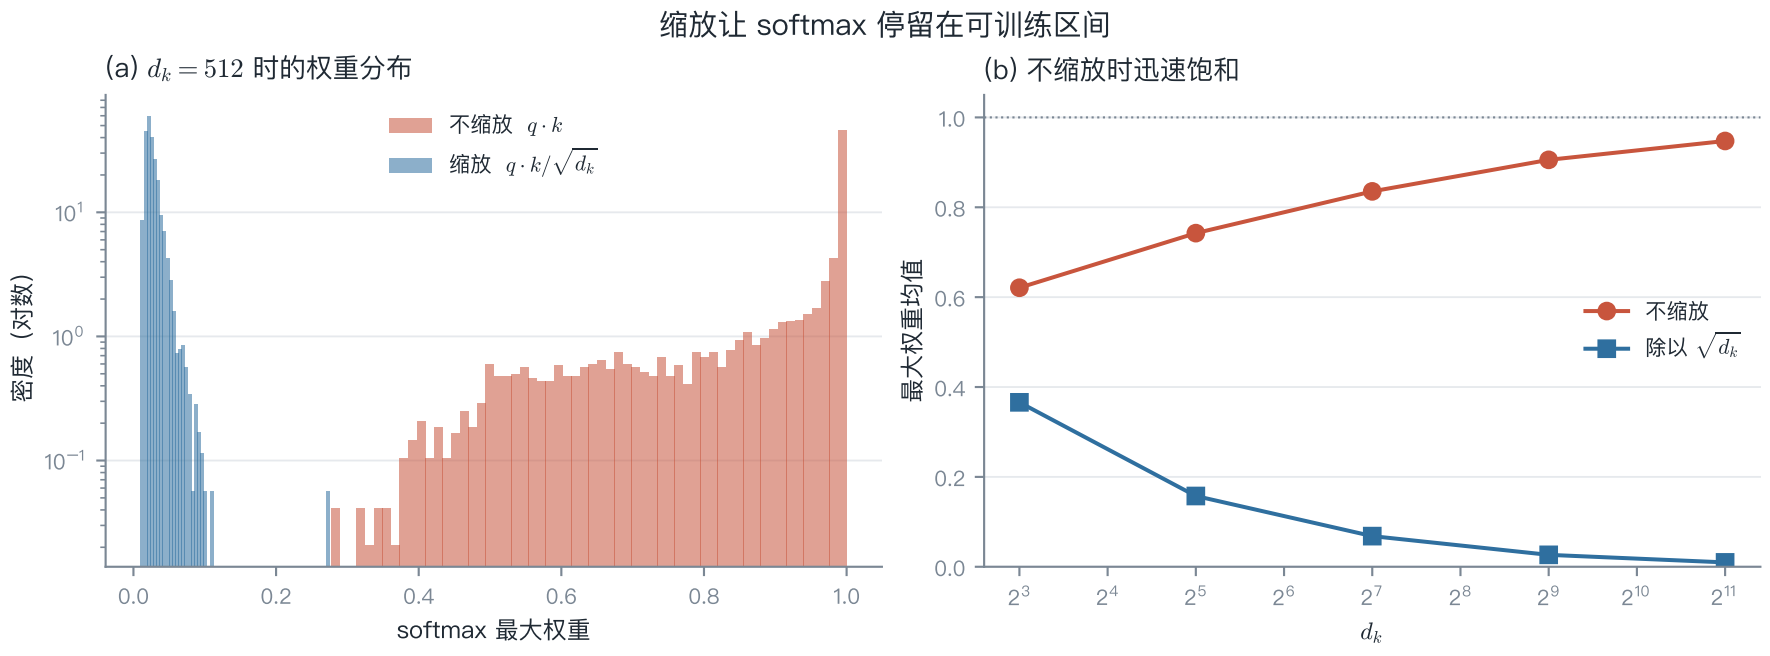
缩放让 softmax 停留在可训练区间
(a) $d_k = 512$ 时的权重分布
不缩放 $q \cdot k$
缩放 $q \cdot k/\sqrt{d_k}$
密度（对数）
10^1
10^0
10^{-1}
0.0
0.2
0.4
0.6
0.8
1.0
softmax 最大权重
(b) 不缩放时迅速饱和
最大权重均值
1.0
0.8
0.6
0.4
0.2
0.0
不缩放
除以 $\sqrt{d_k}$
2^3
2^4
2^5
2^6
2^7
2^8
2^9
2^{10}
2^{11}
d_k