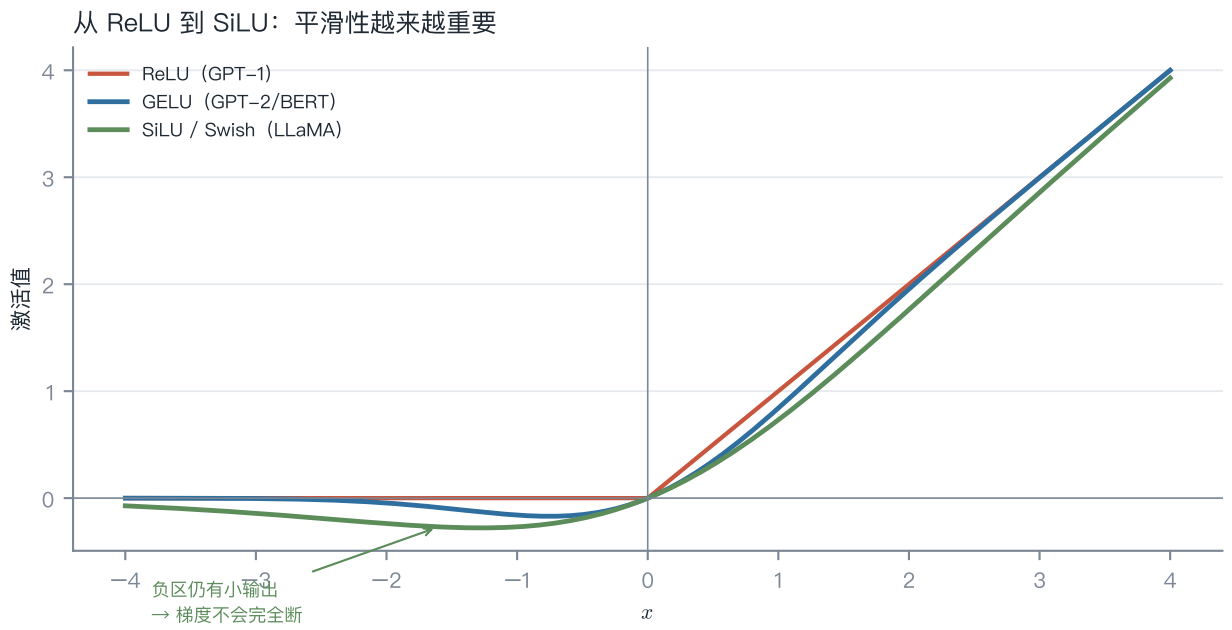
从 ReLU 到 SiLU：平滑性越来越重要
ReLU（GPT-1）
GELU（GPT-2/BERT）
SiLU / Swish（LLaMA）
激活值
4
3
2
1
0
−4
−3
−2
−1
0
1
2
3
4
x
负区仍有小输出
→ 梯度不会完全断
SwiGLU = SiLU(门控分支) ⊙ 线性分支，再降维——三个矩阵换更好的表达力