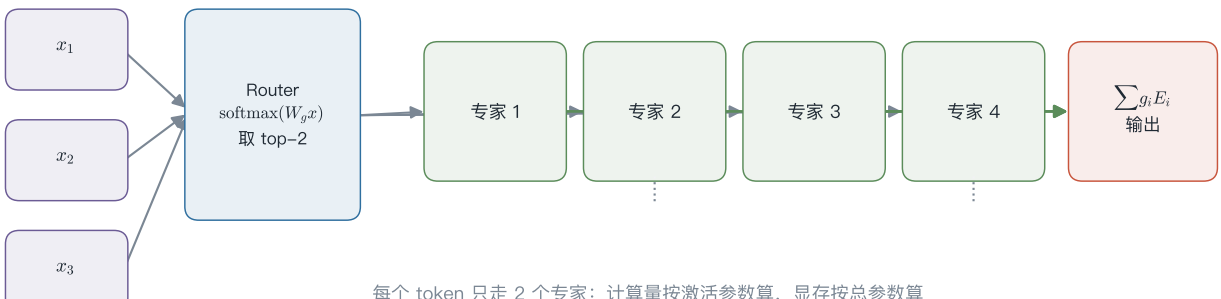

每个 token 只走 2 个专家：计算量按激活参数算，显存按总参数算

灰色箭头是路由打分；实际只有 top-k 条通路被激活

难点不在结构，在「负载均衡」——路由很容易只挑同一个专家