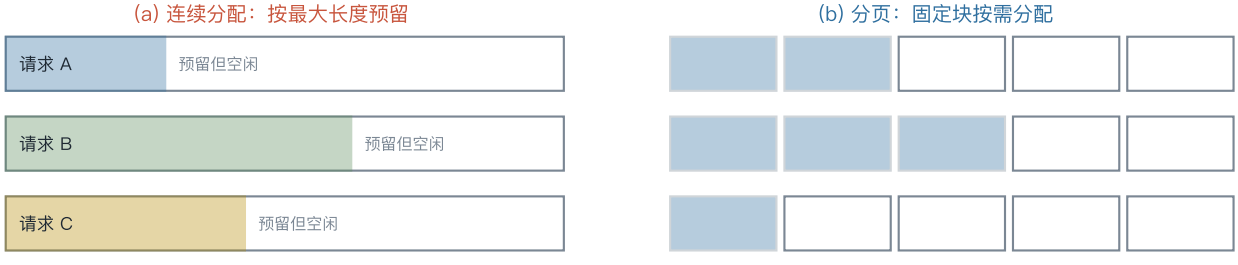

同一块物理显存可以被不同请求的不同位置复用——这就是 PagedAttention 的核心