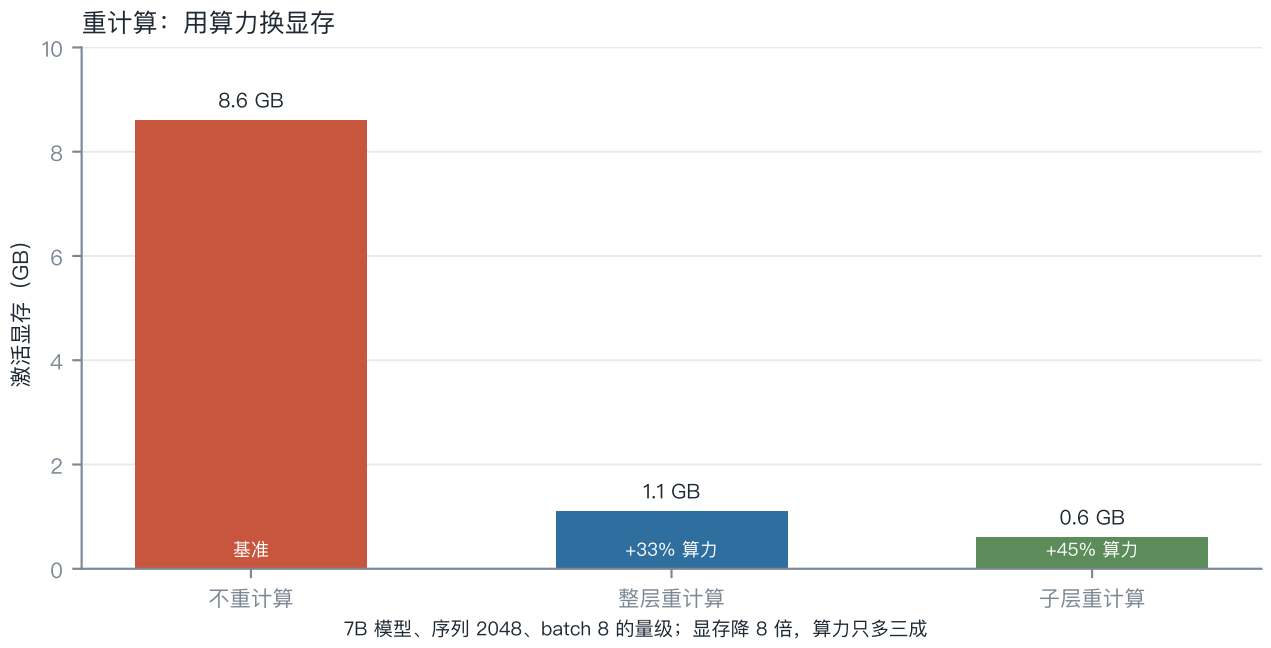
重计算：用算力换显存
激活显存（GB）
10
8
6
4
2
0
8.6 GB
基准
1.1 GB
+33% 算力
0.6 GB
+45% 算力
不重计算
整层重计算
子层重计算
7B 模型、序列 2048、batch 8 的量级；显存降 8 倍，算力只多三成