已生成：

{ | "name" | : | "Ada

当前状态：字符串未闭合 —— 只允许字符串内字符或收尾引号

`"`	`}`	`,`	`a`	`\n`
✓ 合法	✗ 屏蔽	✗ 屏蔽	✓ 合法	✗ 屏蔽

把非法候选的 logit 置为 $-\infty$，再 softmax —— 模型不可能输出半个 JSON

实现：有限状态机（FSM）或下推自动机（PDA）驱动 token 掩码

代价：每步多一次掩码计算；约束太紧会让模型「不会说话」