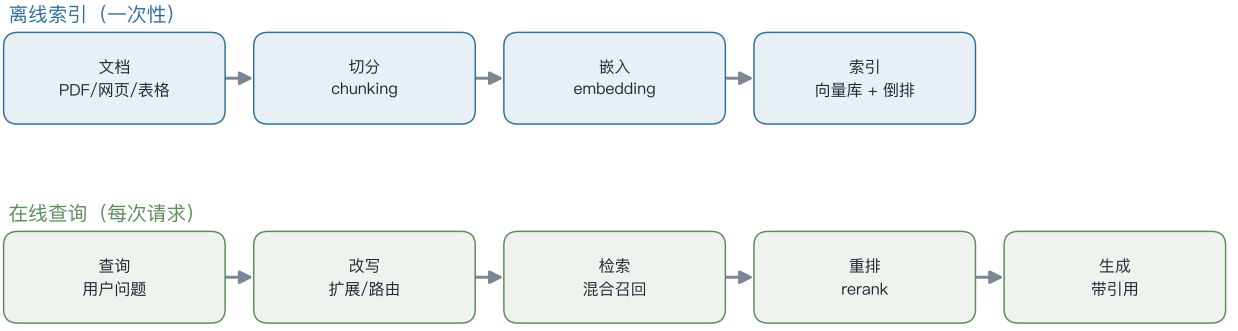

评估要分段：检索错了，生成再好也没用

两个最容易被忽略的环节：切分（决定召回上限）与重排（决定精度）