检索指标决定上限，生成指标决定兑现

上下文精度

检索

检索到的片段里
有多少是相关的

上下文召回

检索

需要的片段
有多少被检索到

忠实度

生成

答案里的每句话
是否有上下文支撑

答案相关性

生成

答案是否真的
回答了问题

排查顺序：先看上下文召回（找不到就一定答错），再看忠实度（找到却编了）