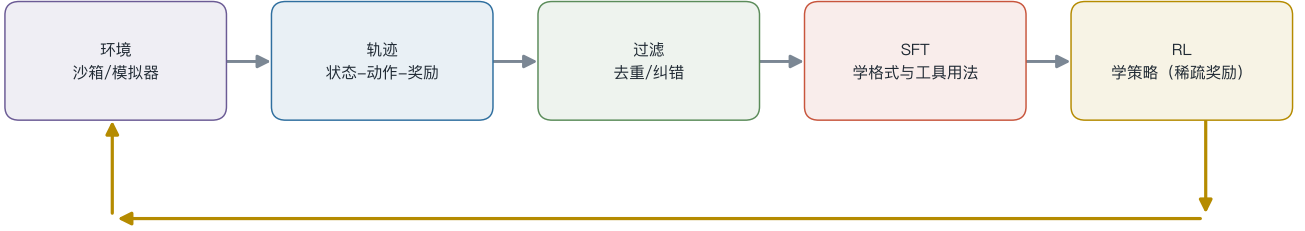

难点：一条 20 步轨迹只有最终对错——信用分配（credit assignment）

对策：过程奖励模型、拒绝采样、把长任务拆成可验证的子目标