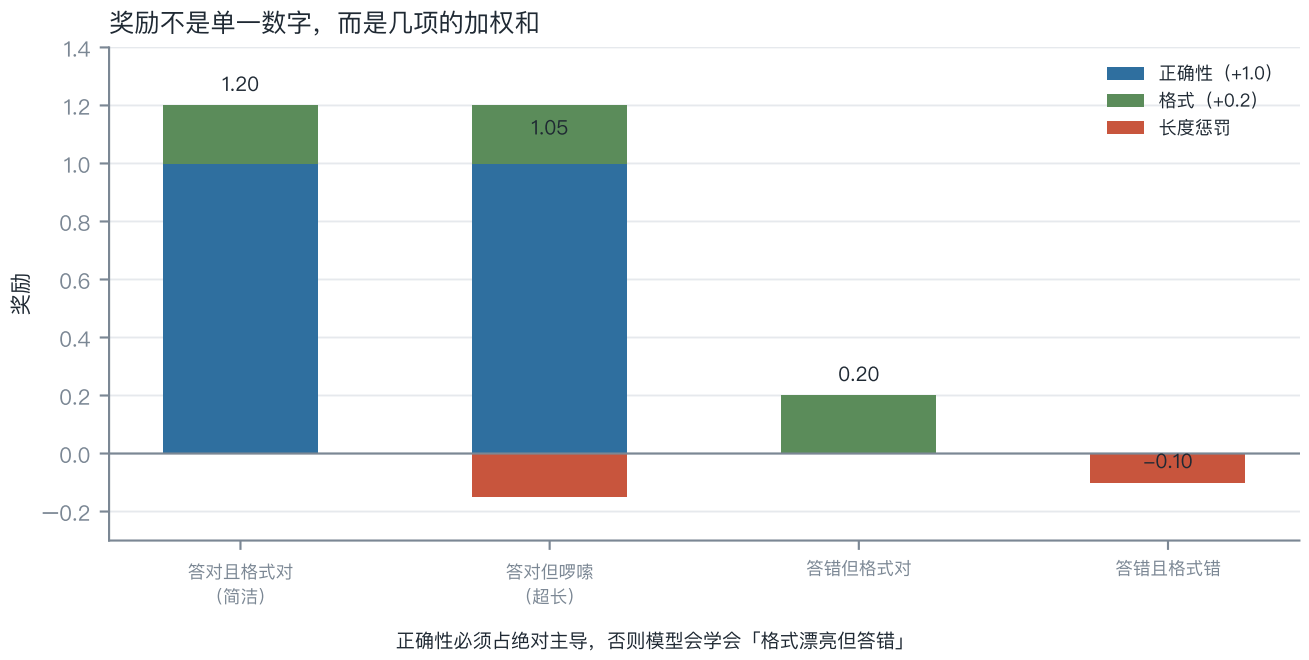
奖励不是单一数字，而是几项的加权和
正确性（+1.0）
格式（+0.2）
长度惩罚
奖励
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
1.20
1.05
0.20
−0.10
答对且格式对
（简洁）
答对但啰嗦
（超长）
答错但格式对
答错且格式错
正确性必须占绝对主导，否则模型会学会「格式漂亮但答错」