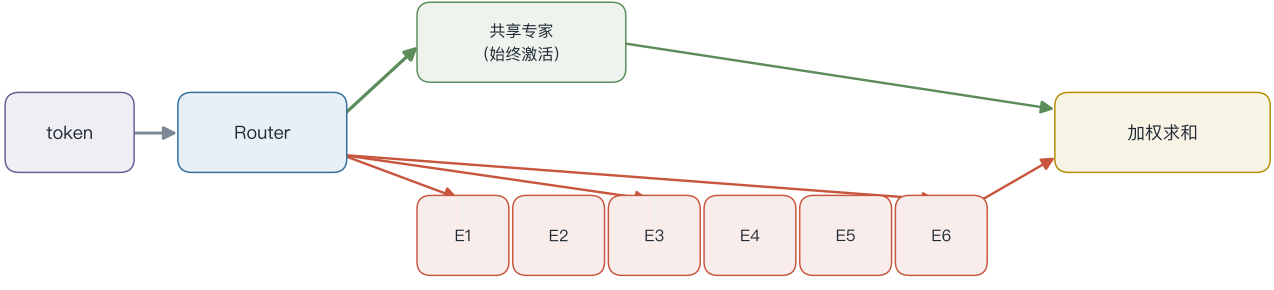

V3：1 个共享专家 + 256 个细粒度专家，每 token 选 8 个

共享专家承载通用知识，细粒度专家承载专门知识——减少冗余

671B 总参数，每 token 只激活 37B（5.5%）