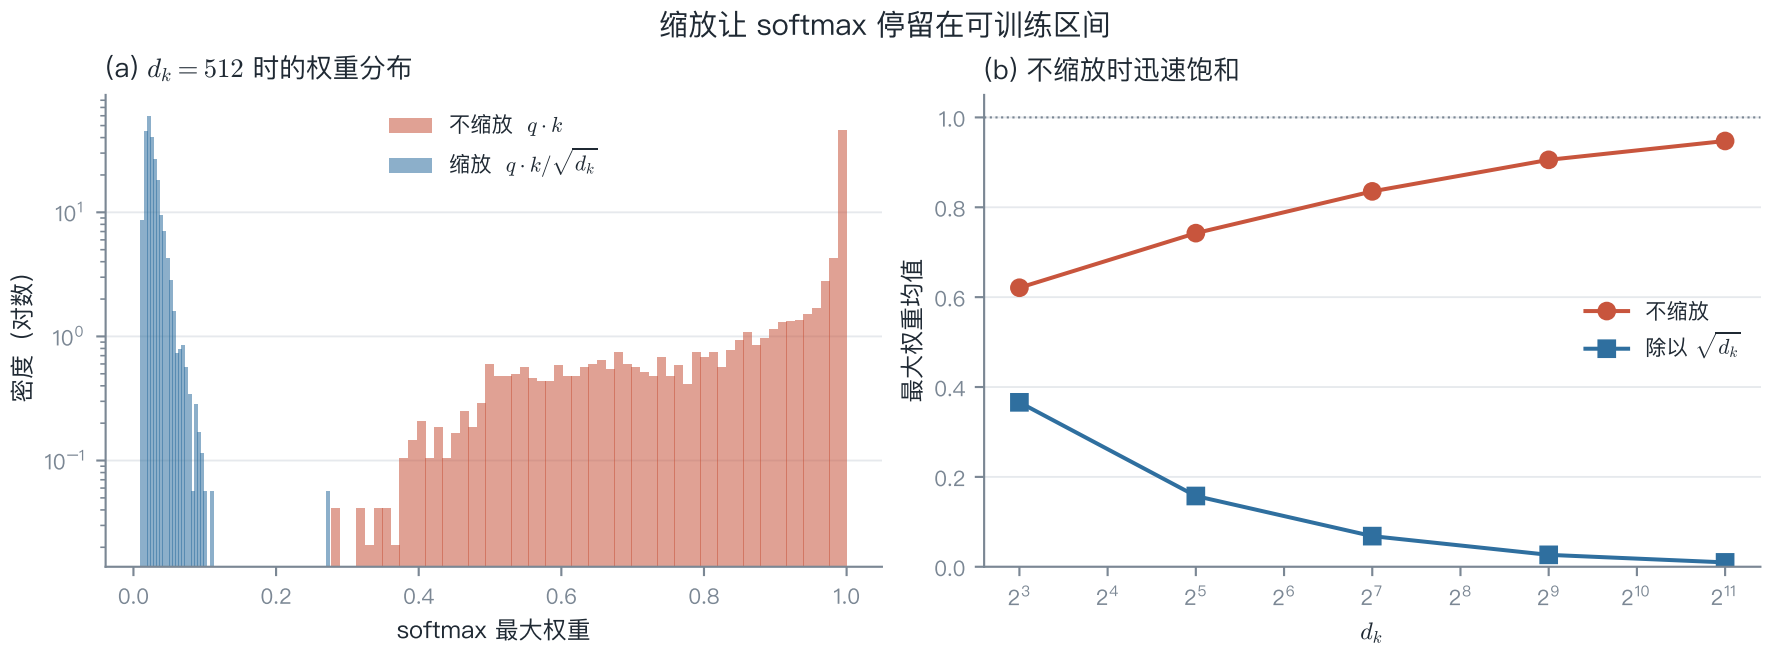
缩放让 softmax 停留在可训练区间
(a) $d_k = 512$ 时的权重分布
不缩放 $q \cdot k$
缩放 $q \cdot k/\sqrt{d_k}$
密度（对数）
$10^1$
$10^0$
$10^{-1}$
0.0
0.2
0.4
0.6
0.8
1.0
softmax 最大权重
(b) 不缩放时迅速饱和
最大权重均值
1.0
0.8
0.6
0.4
0.2
0.0
不缩放
除以 $\sqrt{d_k}$
$2^3$
$2^4$
$2^5$
$2^6$
$2^7$
$2^8$
$2^9$
$2^{10}$
$2^{11}$
$d_k$