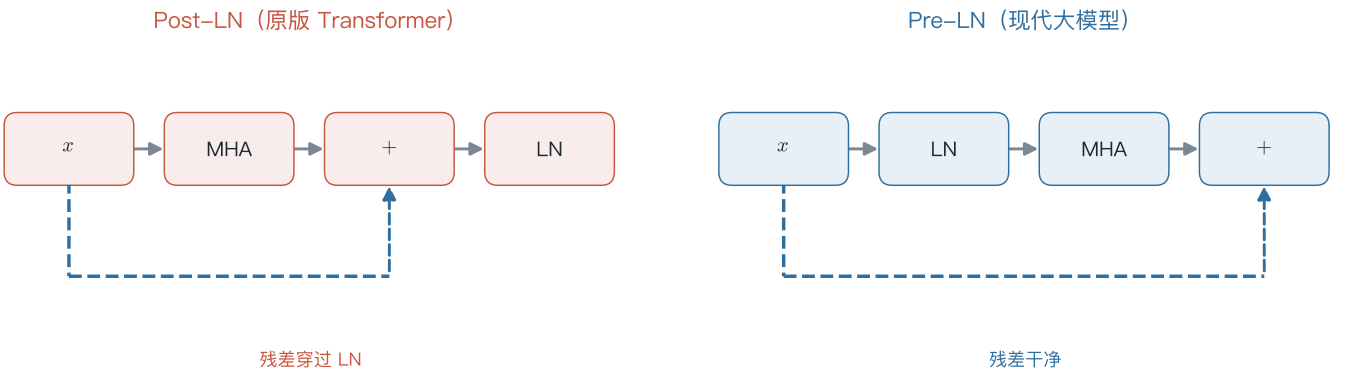

Post-LN 在 12 层以上就要靠 warmup 才能训；Pre-LN 可以直接上 100 层

代价：Pre-LN 的最终层输出未归一化，推理时通常再补一个 LN