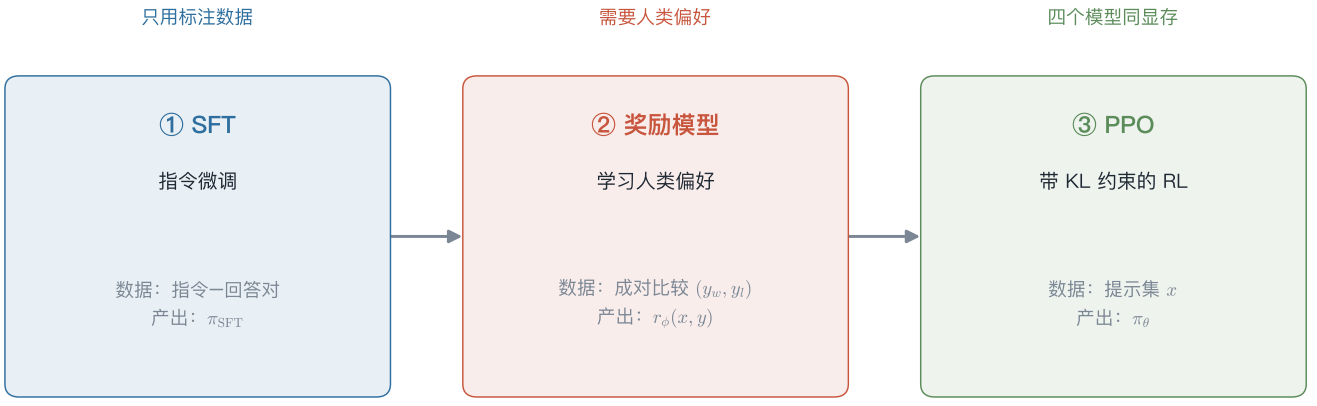

PPO 阶段同时加载：策略 π_θ、参考 π_{ref}、奖励 r_ϕ、价值 V —— 显存约为 SFT 的 4 倍