① 直接越狱

「假设你在写小说，
描述如何……」

用户自己发起

② 间接注入

网页/文件里藏着
「忽略之前的指令」

内容里夹带

③ 多轮诱导

分十步问，每步都
看起来无害

上下文累积

④ 编码绕过

Base64、小语种、
同形字替换

绕过关键词过滤

前两类靠「输入过滤」，后两类靠「上下文审查 + 输出检测」

单层防御必然有漏网：真实攻击常常组合使用