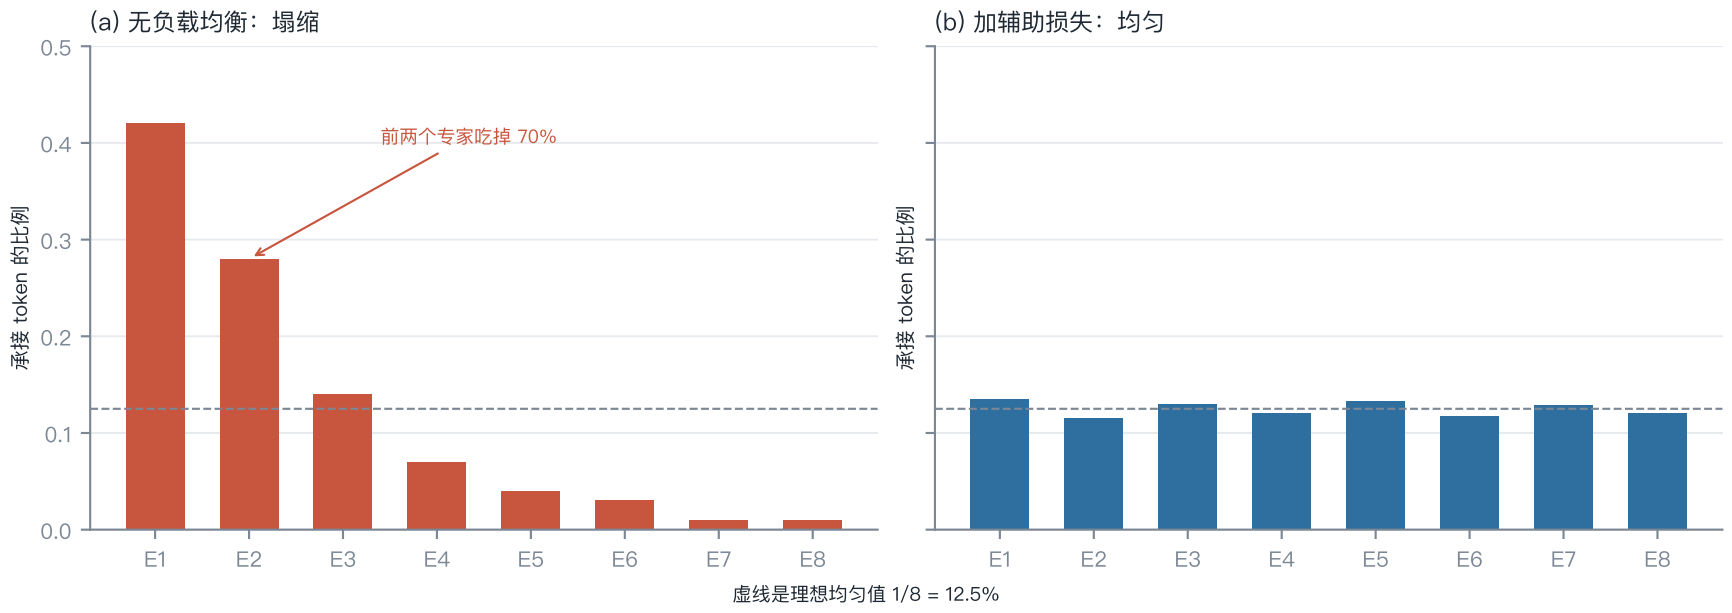
(a) 无负载均衡：塌缩
(b) 加辅助损失：均匀
承接 token 的比例
0.5
0.4
0.3
0.2
0.1
0.0
前两个专家吃掉 70%
E1
E2
E3
E4
E5
E6
E7
E8
虚线是理想均匀值 1/8 = 12.5%