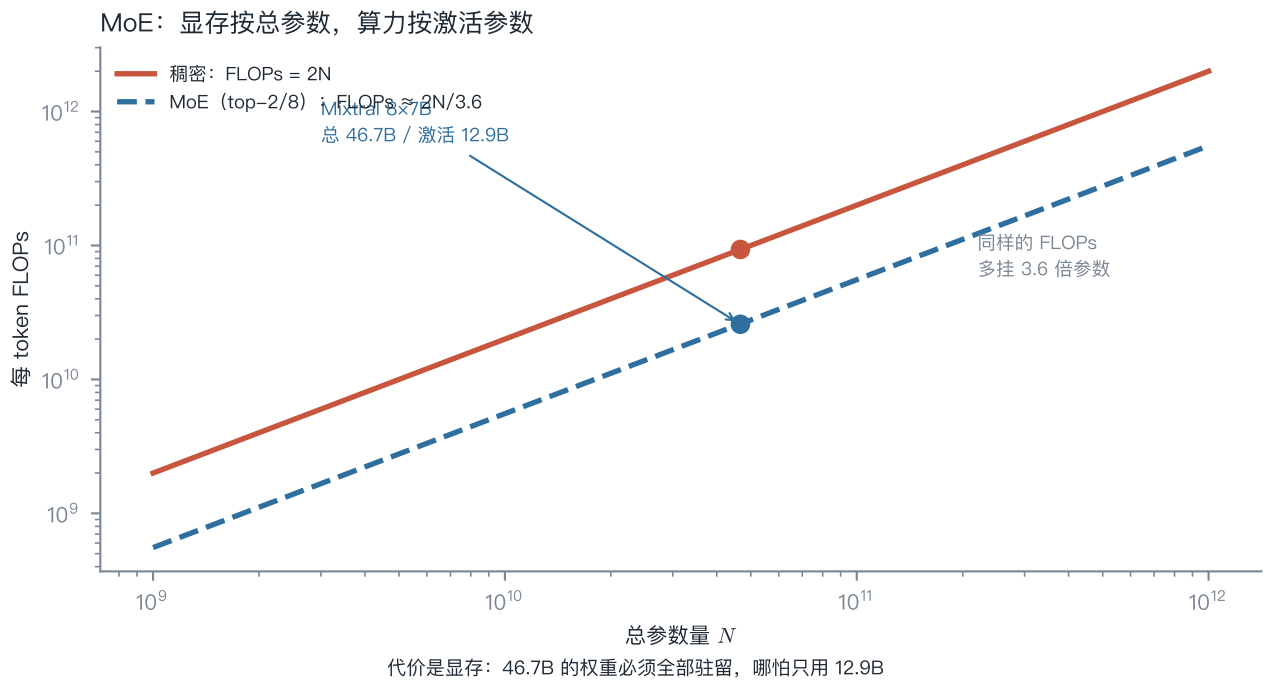
MoE：显存按总参数，算力按激活参数
稠密：FLOPs = 2N
MoE（top-2/8）：FLOPs ≈ 2N/3.6
Mixtral 8×7B
总 46.7B / 激活 12.9B
同样的 FLOPs
多挂 3.6 倍参数
每 token FLOPs
10^{12}
10^{11}
10^{10}
10^{9}
10^{9}
10^{10}
10^{11}
10^{12}
总参数量 N
代价是显存：46.7B 的权重必须全部驻留，哪怕只用 12.9B