通信量 ∝ token 数 × top-k × 隐藏维度

top-2 意味着每个 token 要跨设备跑两趟——这是 MoE 训练慢的主要原因

对策：把 top-k 选中的专家尽量放在同一台机器上（专家亲和调度）