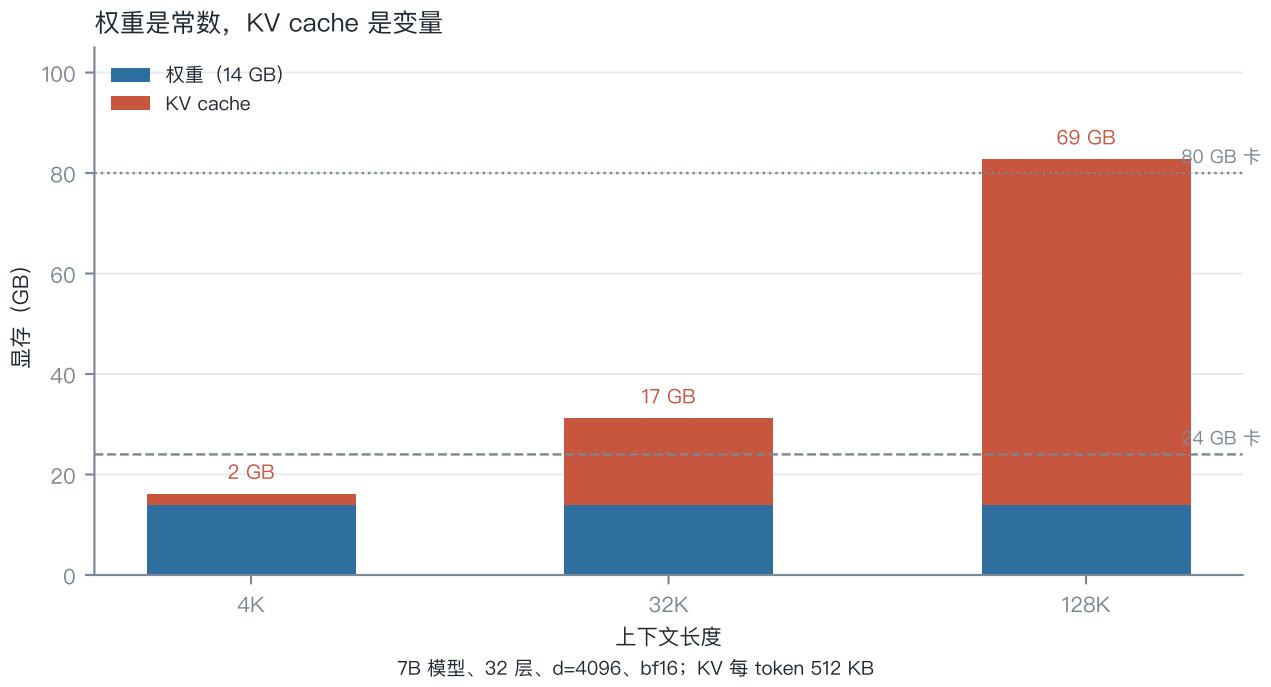
权重是常数，KV cache 是变量
权重（14 GB）
KV cache
100
80
60
40
20
0
显存（GB）
2 GB
17 GB
69 GB
80 GB 卡
24 GB 卡
4K
32K
128K
上下文长度
7B 模型、32 层、d=4096、bf16；KV 每 token 512 KB