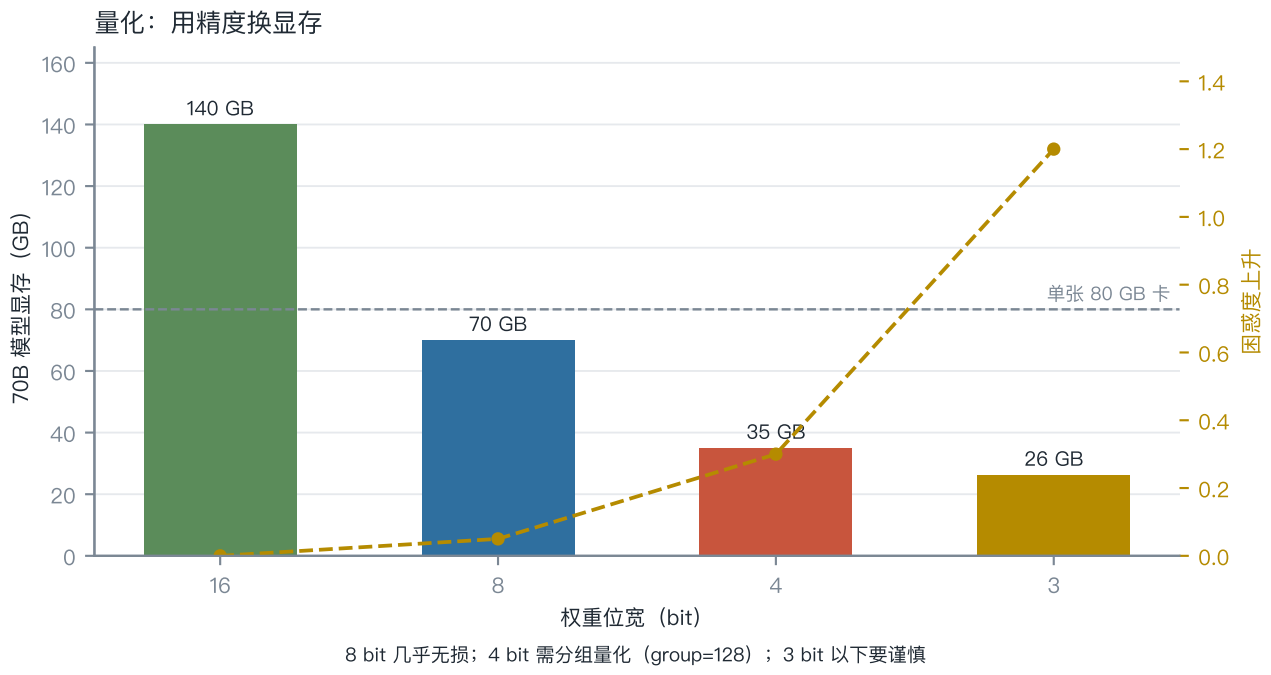
量化：用精度换显存
160
140
120
100
80
60
40
20
0
70B 模型显存（GB）
140 GB
70 GB
35 GB
26 GB
单张 80 GB 卡
1.4
1.2
1.0
0.8
0.6
0.4
0.2
0.0
困惑度上升
16
8
4
3
权重位宽（bit）
8 bit 几乎无损；4 bit 需分组量化（group=128）；3 bit 以下要谨慎