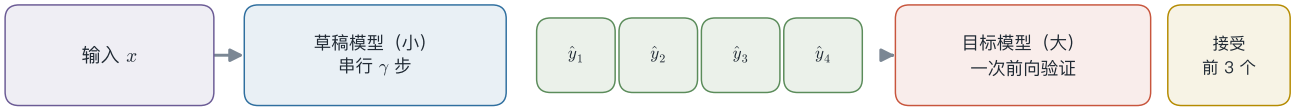

4 个候选里接受前 3 个：一次大模型前向产出 3 个 token

被拒的那个位置按「残差分布」重新采样，保证输出分布不变

加速比 ≈ 接受长度 / (1 + γ × 草稿代价比)

草稿模型越准、越大，接受率越高，但草稿本身也越慢——存在最优 γ