数据并行 DP

每卡一份完整模型
切分 batch

梯度 all-reduce

张量并行 TP

把矩阵按列/行切开
层内切分

每层 all-reduce

流水并行 PP

按层切成若干段
流水执行

段间点对点

专家并行 EP

专家分散到不同卡
token 路由

all-to-all

切得越细，通信越频繁：TP 每层通信，PP 每段通信，DP 每步通信