① 摘要
20 轮历史
摘要成 5 句
继续对话
省 80% token，丢细节
② 裁剪
100 段检索
按相关度排序
保留前 8 段
需要可靠的重排模型
③ 卸载
长文档
存入向量库
按需检索回
本质是 RAG（第 16 讲）
三者常组合：先用摘要压历史，再用裁剪压检索，超长文档走卸载