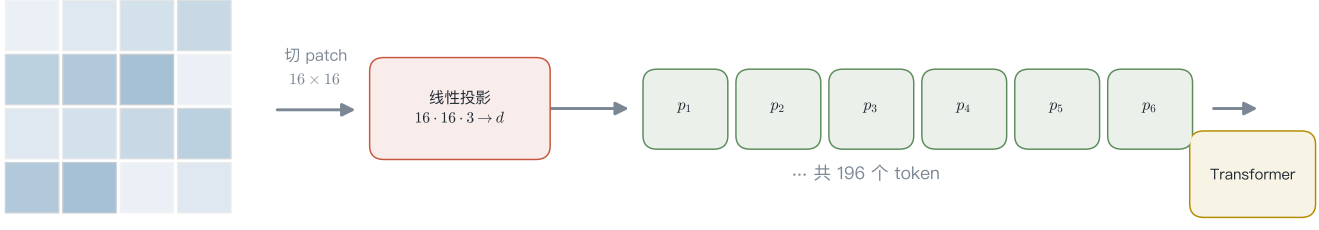

图像不再是「特殊输入」，而是另一种 token 序列

代价：$224/16 = 14$，$14^2 = 196$ 个 token，比一句话还长