(a) Projector（LLaVA）

(b) 交叉注意力（Flamingo）

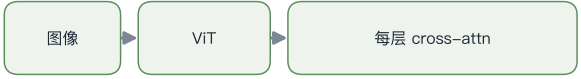

(c) 原生多模态

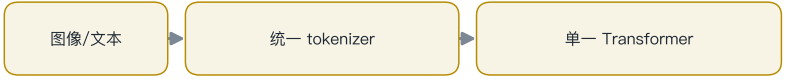

共同点：都把图像变成某种「token」；差别在「在哪一层融合」

融合越早，模型越统一，但训练成本越高