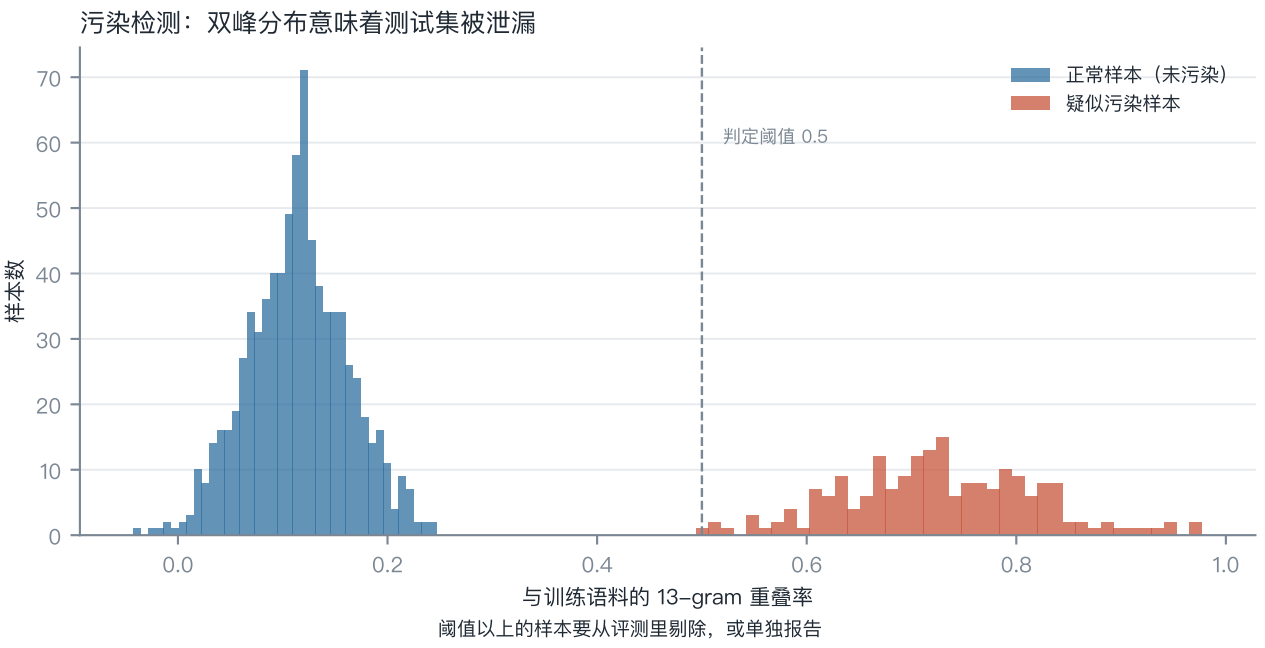
污染检测：双峰分布意味着测试集被泄漏
正常样本（未污染）
疑似污染样本
判定阈值 0.5
样本数
0
10
20
30
40
50
60
70
0.0
0.2
0.4
0.6
0.8
1.0
与训练语料的 13-gram 重叠率
阈值以上的样本要从评测里剔除，或单独报告