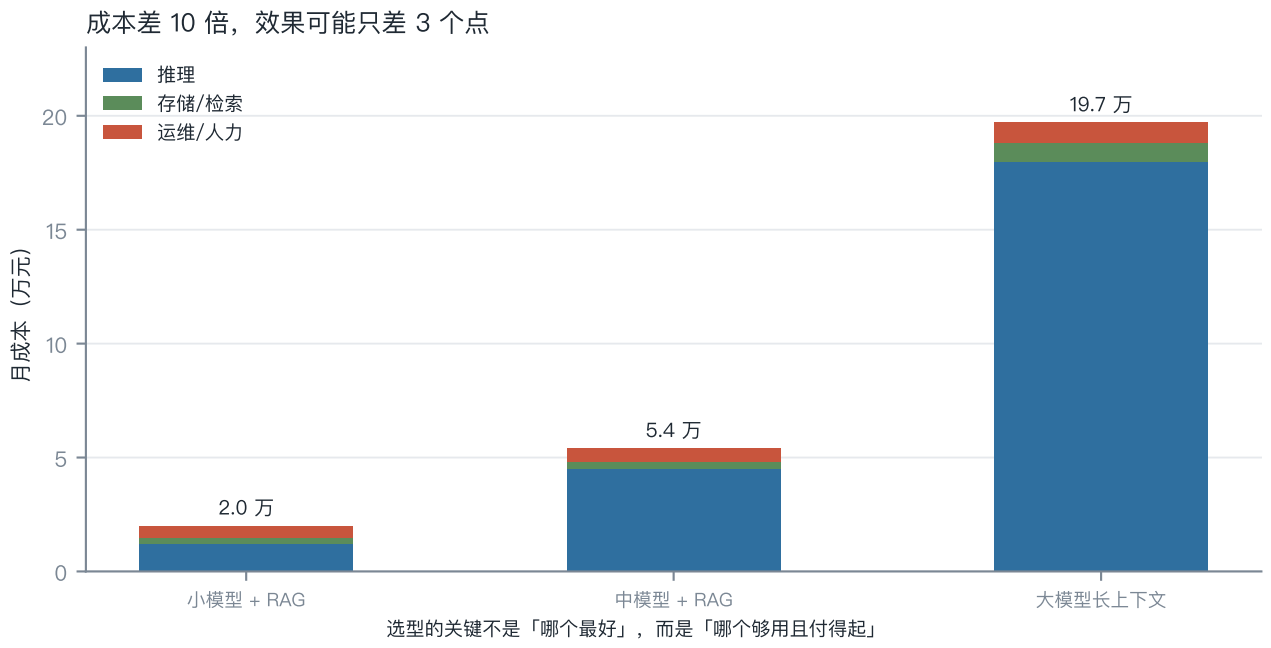
成本差 10 倍，效果可能只差 3 个点
推理
存储/检索
运维/人力
月成本（万元）
0
5
10
15
20
2.0 万
5.4 万
19.7 万
小模型 + RAG
中模型 + RAG
大模型长上下文
选型的关键不是「哪个最好」，而是「哪个够用且付得起」