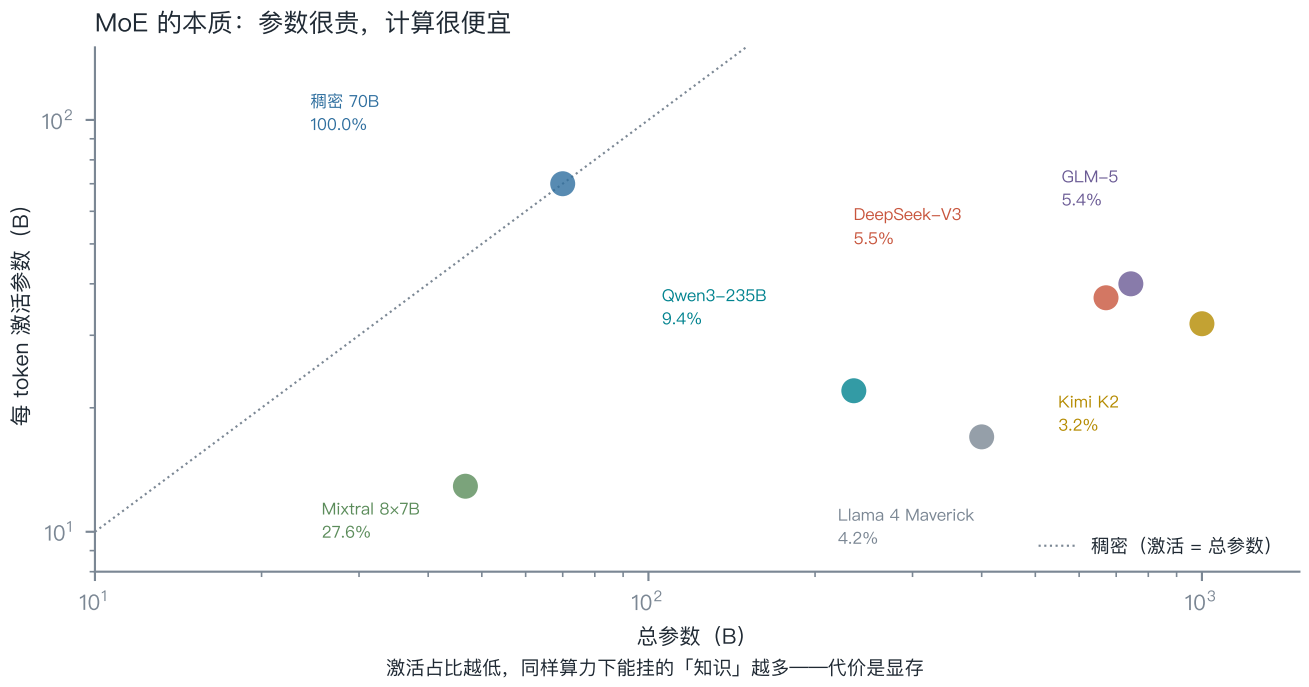
MoE 的本质：参数很贵，计算很便宜
稠密 70B
100.0%
GLM-5
5.4%
DeepSeek-V3
5.5%
Qwen3-235B
9.4%
Kimi K2
3.2%
Mixtral 8×7B
27.6%
Llama 4 Maverick
4.2%
稠密（激活 = 总参数）
每 token 激活参数（B）
10^2
10^1
10^1
10^2
10^3
总参数（B）
激活占比越低，同样算力下能挂的「知识」越多——代价是显存